




DATASET

ว30263

การเขียนโปรแกรมปัญญาประดิษฐ์



DATA SET ?


การนำข้อมูลที่มีคุณสมบัติเหมือนกันมาจัดเป็นชุดให้ถูกต้องตามลักษณะโครงสร้างข้อมูล โดยชุดข้อมูลพื้นฐานที่ใช้กันอย่างแพร่หลายทางด้าน Machine Learning ได้แก่ ชุดข้อมูลดอกไม้ม้า (Iris Dataset) กับ ชุดข้อมูลลายมือตัวเลขอาร์บิท (MNSIT Dataset)



ชุดข้อมูลดอกไม้ (IRIS DATASET)

เป็นชุดข้อมูลพื้นฐานที่ใช้กันอย่างแพร่หลายในด้าน
สถิติและ Machine Learning โดยชุดข้อมูลดอกไม้
ประกอบไปด้วยดอกไม้ 3 สายพันธุ์ได้แก่ Versicolor ,
Setosa , Virginica)





	A	B	C	D	E
1	Sepal Length	Sepal Width	Petal Length	Petal Width	Class
2	5.1	3.5	1.4	0.2	Iris-setosa
3	4.9	3	1.4	0.2	Iris-setosa
4	4.7	3.2	1.3	0.2	Iris-setosa
5	4.6	3.1	1.5	0.2	Iris-setosa
6	5	3.6	1.4	0.2	Iris-setosa
7	5.4	3.9	1.7	0.4	Iris-setosa
8	4.6	3.4	1.4	0.3	Iris-setosa
9	5	3.4	1.5	0.2	Iris-setosa
10	4.4	2.9	1.4	0.2	Iris-setosa
11	4.9	3.1	1.5	0.1	Iris-setosa
12	5.4	3.7	1.5	0.2	Iris-setosa
13	4.8	3.4	1.6	0.2	Iris-setosa
14	4.8	3	1.4	0.1	Iris-setosa
15	4.3	3	1.1	0.1	Iris-setosa
16	5.8	4	1.2	0.2	Iris-setosa
17	5.7	4.4	1.5	0.4	Iris-setosa
18	5.4	3.9	1.3	0.4	Iris-setosa
19	5.1	3.5	1.4	0.3	Iris-setosa
20	5.7	3.8	1.7	0.3	Iris-setosa
21	5.1	3.8	1.5	0.3	Iris-setosa
22	5.4	3.4	1.7	0.2	Iris-setosa
23	5.1	3.7	1.5	0.4	Iris-setosa
24	4.6	3.6	1	0.2	Iris-setosa
25	5.1	3.3	1.7	0.5	Iris-setosa

คุณสมบัติหรือ FEATURE ในชุด ข้อมูลดอกไม้

คือการวัดความกว้างและความยาวของกลีบใบที่เรียกว่า Sepal และ Petal (มีหน่วยเป็นเซนติเมตร cm.)

สรุป :

- Class Label / Target คือ ชื่อข้อมูลที่ต้องการทราบเป็นผลลัพธ์ (Output) เช่น ชื่อสายพันธุ์ ดอกไม้ 3 ชนิด
- Attribute / Features คือ คุณสมบัติของดอกไม้ แต่ละสายพันธุ์ (ความยาว ความสูงหน่วย เซนติเมตร)

iris setosa



petal sepal

iris versicolor



petal sepal



iris virginica



petal sepal


ชุดข้อมูลลายมือ ตัวเลขอารบิก (MNIST DATASET)

ชุดข้อมูลลายมือตัวเลขอารบิกเลข 0-9 มีขนาดรูปภาพ
28 x 28 Pixels มีข้อมูลในชุดเรียนรู้จำนวน 60,000
รูปภาพและข้อมูลชุดทดสอบจำนวน 10,000 รูปภาพ



สรุป :


- Class Label / Target คือ ข้อมูลที่ต้องการทราบเป็นผลลัพธ์ (Output) คือตัวเลข 0-9
- Attribute / Features คือ ภาพวาดลายมือตัวเลข อารบิกแต่ละตัว



BINARY CLASSIFIER

ภายใน LAB จะยกตัวอย่างเพื่อให้เห็นการแบ่งกลุ่มของข้อมูลโดยใช้ MNIST Dataset ว่าข้อมูลกลุ่มใดแสดงกลุ่มตัวเลข 0-9 โดยข้อมูลทั้งหมดจะมี 70,000 ชุดจะต้องเขียนโปรแกรมแบ่งข้อมูลออกเป็น 2 ส่วนได้แก่


- Training Set 60,000 ชุด
- Test Set 10,000 ชุด
 - ข้อมูลชุดเรียนรู้ (Training Set) จัดเรียงและแบ่งกลุ่มเป็น Class 0 – Class 9
 - ข้อมูลชุดทดสอบ (Test Set) จัดเรียงและแบ่งกลุ่มเป็น Class 0 – Class 9



กระบวนการ MACHINE LEARNING จะแบ่งข้อมูลสำคัญๆ ออกเป็น 2 ส่วน


ข้อมูลชุดเรียนรู้ (Training Set) ถูกนำไปเรียนรู้ด้วยวิธีการเรียนรู้เครื่องจักรเพื่อสร้างเป็นโมเดล (Model) จะประกอบไปด้วย label / class เพื่อบอกว่าข้อมูลชุดนี้คืออะไร เช่น ชุดข้อมูลตัวเลข 0-9 , ข้อมูลสายพันธุ์สุนัข เป็นต้น

ข้อมูลชุดทดสอบ (Test Set) ใช้ทดสอบโมเดลที่สร้างขึ้น หากโมเดลที่ทดสอบมีประสิทธิภาพดีจึงจะนำไปใช้งานจริง




GRADIENT DESCENT ALGORITHM

Gradient Descent Algorithm (GD)– อัลกอริทึม
สำหรับใช้หาจุดต่ำสุดหรือสูงสุดของฟังก์ชันที่กำหนดขึ้น
มาโดยใช้วิธีการวนหาค่าที่ทำให้ได้ค่าต่ำสุดจากการ
คำนวณความชัน ณ จุดที่เราอยู่แล้วพยายามเดินไปทาง
ตรงข้ามกับกับความชันนั้น



GRADIENT DESCENT ALGORITHM


หากเราอยู่บนยอดภูเขาไฟ(สีแดง) เราก็จะวนหาทางลงเพื่อเดินทางไปยังทะเล (สีน้ำเงิน) แต่ทะเลมีหลายบริเวณ หากเราเดินทางลงมาจากจุดที่ต่างกันก็จะเห็นทะเลคนละแบบ เช่นเราอยู่ที่จุด A ก็จะเจอทะเลที่น้ำไม่ลึกมาก (Local Minima) ถ้าเราเดินอีกฝั่งหนึ่งก็จะเจอทะเลอีกแบบคือ ทะเลน้ำลึก (Global Minima)



GRADIENT DESCENT ALGORITHM

รูปแบบการใช้งาน

- คำนวณข้อมูลทั้งหมดทีเดียว (Full Batch Gradient Descent Algorithm)
- คำนวณข้อมูลแค่บางส่วน (Stochastic Gradient Descent Algorithm)



DATA CLEANSING

ข้อมูลสกปรกตรงไหน ทำไมเราจึงต้องทำความสะอาด
ก่อนใช้กระบวนการตรวจสอบ สะสาง แก้ไข หรือจัดรูป
แบบข้อมูลให้อยู่ในสภาพที่พร้อมใช้งานที่สุด รวมไปถึง
คัดกรองข้อมูลที่ไม่ถูกต้องหรือไม่จำเป็นออกไปจากชุด
ข้อมูลที่จะใช้วิเคราะห์หรือประมวลผล



Data Cleaning

DATA ลักษณะข้อมูล แบบไหนที่ต้องทำ DATA CLEANSING

ชุดข้อมูลที่ไม่ได้อยู่ในรูปแบบหรือไฟล์ประเภทเดียวกัน
กรณีนี้ อาจเกิดจากการที่มีข้อมูลจากหลากหลายฐาน
ข้อมูล (database) เมื่อมาจากหลากหลายแหล่ง จึงมี
โอกาสที่แต่ละแหล่งจะจัดเก็บข้อมูลกันคนละสกุลไฟล์
เช่น จัดเก็บข้อมูลเป็นไฟล์ .pdf ไฟล์ excel หรือสกุลไฟล์
อื่นๆ ที่ไม่คุ้นเคย เมื่อจำเป็นต้องนำมาประมวลผลด้วย
กัน จึงไม่สามารถทำได้



Data Cleaning

DATA ลักษณะข้อมูล แบบไหนที่ต้องทำ DATA CLEANSING

ข้อมูลไม่ได้ถูกจัดเก็บในรูปแบบที่ต้องการ
เราจำเป็นต้องทำให้ข้อมูลอยู่ในรูปแบบที่พร้อมสำหรับ
การวิเคราะห์ข้อมูลหรือนำไปสู่ report หรือคำตอบที่เรา
ต้องการได้ ยกตัวอย่างเช่น เราต้องการทราบร้านคู่แข่ง
ในแต่ละเขต/อำเภอ แต่ข้อมูลที่มีอยู่นำเข้ามาจาก Open
Source ที่แบ่งพื้นที่ตามพิกัด GPS (ละติจูด-ลองจิจูด)
เราจึงต้องแปลงข้อมูลที่ได้ให้เป็นแบบเขต/อำเภอ ก่อน



Data Cleaning

DATA ลักษณะข้อมูล แบบไหนที่ต้องทำ DATA CLEANSING

ส่วนใหญ่ข้อมูลที่กรอกหรือนำเข้าสู่ระบบโดยคน อาจมี
ข้อผิดพลาด (human errors) บ้างเป็นธรรมดา เช่น
การกรอกข้อมูลผิดช่อง การกรอกข้อมูลที่ไม่มีทางเป็น
ความจริง การกรอกข้อมูลที่ถูกตัดแต่ไม่ตรงกับข้อมูล
หลัก



Data Cleaning

การเรียก ใช้ข้อมูล


MNIST DATASET



```
1  import pandas as pd
2  dataset = pd.read_csv("digit-recognizer/train.csv")
3  print(dataset.shape)
4  print(dataset.head())
5
6  # Separating input values from labels.
7  y_train = dataset['label']
8  x_train = dataset.drop('label', axis=1)
9
```

การ แสดง ภาพ

MNIST DATASET



```
1 image = x_train.iloc[8].values
2 image = image.reshape(28, 28)
3
4 plt.imshow(image, cmap='gray')
5 plt.title(f"Label: {y_train.iloc[8]}")
6 plt.show()
```



ဟဟဟ!!!!!!!!!!!!!!